

MINI PROJECT STRUKTUR DATA BIOINFORMATIKA

Analisis GC Content pada Data Sekuens DNA Menggunakan Python

Nama: Asril Maulana Akbar

NIM: G0401241053

Mata Kuliah: Struktur Data Bioinformatika (BIF1223)

1. Pendahuluan

Bioinformatika merupakan bidang ilmu yang menggabungkan biologi, komputer, dan statistika untuk menganalisis data biologis. Salah satu data yang sering digunakan adalah data sekuens DNA yang tersimpan dalam format FASTA maupun FASTQ.

Pada mini project ini dilakukan analisis sederhana terhadap data sekuens DNA menggunakan bahasa pemrograman Python. Analisis yang dilakukan meliputi pembacaan file FASTA, perhitungan frekuensi nukleotida, perhitungan GC Content, pengurutan sekuens berdasarkan nilai GC Content, visualisasi data, dan penyimpanan hasil ke dalam file CSV.

2. Metode

Data sekuens diperoleh dari database NCBI dalam format FASTA. Program Python dikembangkan menggunakan library Biopython, Pandas, dan Matplotlib.

Tahapan analisis yang dilakukan:

1. Membaca file FASTA.
2. Menyimpan data sekuens ke dalam List.
3. Menghitung frekuensi nukleotida A, T, G, dan C menggunakan Dictionary.
4. Menghitung GC Content setiap sekuens.
5. Mengurutkan sekuens berdasarkan nilai GC Content.
6. Menampilkan tiga sekuens dengan nilai GC Content tertinggi.
7. Membuat grafik GC Content.
8. Menyimpan hasil ke file CSV.
9. Membuat file html

3. Hasil dan Pembahasan

- **Data lengkap**

	ID	Length	A	T	G	C	GC_Content
1	OZ221990.1	3221	739	913	702	861	48.53
3	AF090842.1	3221	742	921	704	854	48.37
0	NC_075114.1	3248	739	941	700	868	48.28

4	AB064310.1	3248	740	940	700	868	48.28
5	AF160501.1	3248	739	941	700	868	48.28
2	AF405706.1	3248	741	940	699	868	48.25

Program berhasil membaca seluruh sekuens pada file FASTA. Frekuensi masing-masing nukleotida dihitung dan digunakan untuk menentukan nilai GC Content.

- **Top 3 GC Content**

ID GC_Content


1 OZ221990.1 48.53

3 AF090842.1 48.37

0 NC_075114.1 48.28

Hasil pengurutan menunjukkan bahwa beberapa sekuens memiliki kandungan GC yang lebih tinggi dibandingkan sekuens lainnya. Nilai GC Content yang tinggi menunjukkan proporsi basa Guanin dan Sitosis yang lebih besar pada sekuens tersebut.

- **Grafik hasil**



Grafik yang dihasilkan memberikan visualisasi distribusi GC Content antar sekuens sehingga memudahkan interpretasi hasil analisis.

4. Kesimpulan

Program berhasil melakukan analisis sederhana terhadap data sekuens DNA menggunakan struktur data List dan Dictionary. Analisis meliputi perhitungan frekuensi nukleotida, GC Content, pengurutan sekuens, visualisasi grafik, serta penyimpanan hasil ke file CSV. Hasil menunjukkan bahwa Python dapat digunakan secara efektif untuk membangun pipeline bioinformatika sederhana.

5. Lampiran

File Edit Selection View Go Run mini_project_strukdat

Mini Project Bioinformatika file:///.../csv.html grafik.html Mini Project Bioinformatika file:///.../gc.html

file:///c:/3A/mini_project_strukdat/gc.html

EXPLORER

MINI_PROJECT_STRUKDAT

css

csv

data

grafik

html

laporan

aes.html

coba.html

csv.html

frekuensi.html

gc.html

grafik.html

hasil

header.jpeg

index.html

projek.html

projek.py

style.css

tes.py

top3.html

OUTLINE

TIMELINE

Home

Frekuensi

GC Content

Top 3 GC

CSV

Grafik

GC Content

ID	GC Content (%)
OZ221990.1	48.53
AF090842.1	48.37

PROBLEMS

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

=== DATA LENGKAP ===

ID	Length	A	T	G	C	GC_Content
1 OZ221990.1	3221	739	913	702	861	48.53
3 AF090842.1	3221	742	921	704	854	48.37
0 NC_075114.1	3248	739	941	700	868	48.28
4 AB064310.1	3248	740	940	700	868	48.28
5 AF160601.1	3248	739	941	700	868	48.28
2 AF405706.1	3248	741	940	699	868	48.25

File CSV berhasil dibuat: hasil.csv

Code

powersh...

Code

Mini Project Bioinformatika

Describe what to build

+ Auto

Local

Default Approves

Go Live

26°

Search

21:00

27/06/2026